

생체 신호 데이터를 이용한 애착 장소 분석

김은지* 배정민* 이승준* 조지환*

*동국대학교 통계학과

{ej2747, vz0502, lsj7087, g0702853}@naver.com

"Attachment Place Analysis using Biosignals Data"

Eunji Kim*, Jeongmin Bae*, Seungjun Lee*, Jihwan Cho*

*Dept. of Statistics, Dongguk University

요 약

본 연구는 E4 모바일 웨어러블 디바이스를 통해 수집된 생체 신호 데이터를 활용하여 사용자의 애착 장소를 분석하는 것을 목적으로 한다. 생체 신호 데이터 중 특히 Accelerometer(Acc), Blood Volume Pressure(Bvp), Electrodermal Activity(Eda), Heart Rate(Hr), Skin Temperature(Temp)를 이용하여 사용자의 장소를 예측하는 Multi-Resolution CNN 모델을 구성하였다. 이후 모델이 오분류한 시점의 gps 데이터를 이용하여 사용자 별 애착 장소를 분석하는 방법에 대한 제안을 한다.

1. 서 론

장소애착은 집과 같은 장소에서 느낀 정서적 관련이나 감정적 유대를 특정 장소에서도 느끼는 것을 말한다. 대표적으로 집이라는 공간은 일반적으로 편안함, 안정감을 의미하는 장소이다 [1]. 개인은 특정 장소에서 느낀 경험과 개인의 성향을 통해 그 장소와 연관된 특별한 감정을 형성하며, 이러한 장소들을 애착 장소(Attachment Place)라고 한다.

장소애착 형성을 위해서는 특정 장소에서의 일정한 시간이 요구된다. 하지만 장소애착의 형성이 단지 방문 빈도나 장기간에 의해 이루어지는 것만은 아니다. 단기간의 강한 감정적 유대도 장소애착 형성에 영향을 준다. 따라서, 본 연구는 장소에서 느끼는 감정이 애착 장소 형성에 영향을 준다고 가정한다 [2]. 이와 같은 이유로 단순 시간적 요소가 아닌 개인의 감정에 기반하여 애착 장소를 분석하는 것이 필요하다.

본 연구에서는 E4 모바일 웨어러블 디바이스를 통해 수집된 Accelerometer(Acc), Blood Volume Pressure(Bvp), Electrodermal Activity(Eda), Heart Rate(Hr), Skin Temperature(Temp) 데이터를 사용했다. 기존 연구에 따르면, 생체 신호 데이터를 통해 사용자가 스트레스를 받는 상황인지, 안정감을 느끼는 상황인지 등을 파악할 수 있으며 [3], 사용자의 감정 상태를 예측할 수 있다 [4]. 특히, Hr, Temp, Eda는 스트레스를 검출하는 연구에서 많이 사용되는 생체 정보이다. 따라서 위 생체 신호 데이터로 사용자의 감정을 파악할 수 있다는 점을 이용하여 장소를 예측하는 모델을 개발하였다.

사후 분석에서는 모델이 오분류한 시점을 고려하였다. 해당 timestamp의 gps 데이터를 이용하여 사용자가 집과 비슷한 감정을 느끼는 집 이외의 장소에 대해 분석하였다. 그리고 gps 데이터를 지도에 시각화 함으로써 패턴을 파악하였다.

2. 관련 연구

2.1 생체 신호와 감정 간의 연관성

생체 신호와 감정 간의 연관성은 많은 연구에서 입증되어 왔다. 예를 들어, 인간의 Hr이 매우 안정되면 이는 안정적인 상태를 나타내며 스트레스 상황에서는 Hr이 불안정해진다. 생체 신호들 중에서도 가장 많이 연구되고 있는 것은 심박변이도(HRV; Heart Rate Variability)이다. 예를 들어, Valenza etc.(2014) 연구에서는 HRV와 감정 간의 밀접한 연관성이 있음을 발견하였다 [5]. 또한 Koelstra etc.(2012) 연구에서는 HRV, Eda 등의 생체 신호가 다양한 감정 상태와 밀접한 연관성이 있음을 발견하였다 [6]. 이러한 연구들은 생체 신호와 감정 간의 연관성을 객관적으로 입증하였다.

2.2 장소 인식

위치 정보를 기반으로 사용자의 이동패턴을 분석하거나 실제 위치 예측을 시도하는 연구들이 활발히 이루어지고 있다. SNS 텍스트 데이터와 시계열 통화량 데이터를 이용하여 지역별 이동 패턴을 탐색하는 기존의 연구가 있다 [7]. gps 센서의 환경에 따른 불안정한 관측 문제를 개선하기 위해 사용자의 장소 변화 시퀀스를 분석하여 현재 장소를 인식하는 연구가 진행되었다 [8]. 본 논문에서는 기존 연구와 차별화하여 감정 신호 센서 데이터를 활용한 사용자 별 애착 장소를 분석하고자 한다.

2.3 시계열 CNN 모델

시계열 자료는 이미지와 형식이 비슷하기 때문에, 시계열 패턴 분석을 위하여 CNN(Convolutional Neural Network)을 사용하는 경우가 많다. 본 연구에서는 CNN을 사용하여 생체 신호를 이용한 장소 예측을 진행하려고 한다. 관련 연구를 살펴보면 넓은 크기의 kernel은 상대적으로 낮은 주파수, 작은 크기의 kernel은 상대적으로 높은 주파수에 대한 특징을 추출한다는 것을 알 수




그림 1. MR-CNN 모델 구조

있다 [9]. 따라서, kernel 크기가 다른 1D Convolutional Layers로 이루어진 Multi-Resolution CNN을 이용하여, branch 별로 서로 다른 주파수 영역에 대한 특징을 추출할 수 있다. 본 연구에서는 3개의 다른 kernel 크기를 가진 1D Convolutional Layers를 이용하여 모델을 구성하였다.

3. 실험 설정

3.1 데이터셋

본 논문은 2020년 피실험자 22명의 라이프로그 데이터를 사용하였다 [10]. 라이프로그 데이터는 모바일 웨어러블 디바이스를 통한 수동적 수집 기록과 사용자의 일정 부분의 행위가 요구되는 능동적 수집 기록으로 나뉜다. 우리는 모바일 웨어러블 디바이스를 통해 수동적으로 수집되는 기록으로부터 사용자의 애착 장소를 파악하는 것을 목표로 한다.

데이터는 모바일 웨어러블 디바이스 E4와 모바일 센서로 수집되었으며 e4Acc, e4Bvp, e4Eda, e4Hr, e4Temp, mAcc, mGps, mGyr, mMag의 총 9개의 속성으로 구성되어 있다. 그 중 생체 신호와 관련된 모바일 웨어러블 디바이스 E4로 수집된 속성들만 사용했다. e4Acc, e4Bvp, e4Eda, e4Hr, e4Temp는 각각 다른 시간 단위로 수집되었다.

Bvp와 Hr은 스트레스와 상관관계 및 인과관계가 있으며 Eda와 Temp는 각각 피부전도도와 피부온도를 의미하며 피부전도도와 피부온도가 스트레스 관련 임상 연구에서 자율신경계의 반응을 조사하는 연구에 활용되는 속성이다. Acc는 신체움직임을 의미하며 신체 움직임과 감정이 관련이 있다는 연구가 있다[11]

본 논문에서는 1분 동안 측정된 시계열 데이터들을 입력으로 사용한다. 변수별로 상이하게 1/10초 ~ 1/100초 사이의 간격으로 측정이 되어 데이터의 길이가 다르기 때문에 통계량 평균값을 이용하여 1초 간격으로 변환하였다. 최종적으로 분석에 사용된 변수 e4Acc_x, e4Acc_y, e4Acc_z, e4Bvp, e4Eda, e4Hr, e4Temp 7개의 변수 모두 길이가 60인 데이터로 입력된다. 변환 이후에 데이터의 길이가 60초 미달인 데이터는 제외하였다.

장소는 사용자의 입력으로 수집되었으며 home, workplace, restaurant, outdoor, other_indoor 로 구성되어 있다.

3.2 연구 방법

E4 데이터의 피실험자 22명 중 1명의 데이터는 개인별 애착 장소 파악 사후 분석을 위하여 독립적으로 분리하였다. 나머지 21명의 데이터는 장소 예측 모델 학습을 위해 전체 데이터를 학습용 데이터셋, 검증용 데이터셋, 테스트용 데이터셋으로 분리하였고 60초 동안 관측되어 라벨링된 하나의 Timestamp가 무작위로 분리되지 않도록 60행씩 나눠지도록 하였다.

학습된 모델을 통해 예측한 장소와 실제 장소의 차이가 나타나는 시점에 집중하여 사후 분석을 진행한다.

3.3 모델 구조

본 생체 신호 데이터를 통해 장소를 예측하는 실험은 대표적인 시계열 딥러닝 모델인 1D-CNN 모델을 사용하였다. 1D-CNN은 합성곱 층(Convolution Layer)의 커널 크기에 따라 합성곱 연산이 되는 데이터 시퀀스가 달라진다.

모델에 사용되는 데이터가 생체 신호 데이터라는 특성에 따라 주파수의 파동의 간격이 불특정하기 때문에 다양한 크기의

커널을 반영하고자 그림 1과 같이 다수의 CNN 모델의 feature를 병합한 MR-CNN 모델을 사용하였다.

첫번째 단계에서는 총 3개의 CNN 모델을 병렬적으로 각 모델마다 합성곱 층을 2계층씩 쌓아서 구성하였다. 모델의 필터 수는 128개로 동일하게 설정하였고, 커널의 크기는 제각각 2, 3, 5 길이로 설정하여 합성곱 신경망이 생체 신호 데이터를 세부적으로 다양한 길이로 학습할 수 있게 하였다. 다음 단계에서는 3개의 모델이 학습하여 추출된 feature들을 일렬로 병합한 후에 다시 합성곱 층에 입력함으로써 종합적으로 학습이 이루어지도록 설정하였다.

4. 실험 결과

4.1 모델 결과

본 논문에서 E4 센서 데이터를 통해 장소를 예측한 모델의 성능 평가는 검증용 데이터 셋의 F1-score와 Loss-Function 그래프를 이용했다. 클래스 불균형을 고려하기 위해 Micro, Weighted F1-score 비교하여 최종적으로 Weighted F1-score를 반영하였다. 또한 학습용 데이터 셋과 검증용 데이터 셋 사이의 Loss값이 일정 수준 이상부터는 큰 차이가 없는 반복 수까지 학습을 진행시켰다. 최종 선정된 모델에 테스트용 데이터를 적용시킨 결과 Weighted F1-score는 0.6164로 나타났다.

	Weighted F1-score	Micro F1-score
1D-CNN	0.5867	0.5648
1D-CNN + LSTM	0.5895	0.5735
1D-CNN + Bi-LSTM	0.5926	0.5787
MR-CNN + Bi-LSTM	0.5846	0.5691
MR-CNN	0.6164	0.6037

표 1. 모델 구조에 따른 모델별 성능 결과

4.2 사후 분석 및 활용 방안

장소애착은 집에서 느끼는 감정적 유대를 특정 장소에서도 느끼는 것을 기반으로 한다. 그러므로 사후 분석에서는 개인 별 애착 장소 파악을 위해 장소 예측 모델이 “home”이라고 오분류한 경우만을 사용했다.

본 연구에서는 장소 특성의 용이성을 위해 실제 장소가 “other_indoor”인 경우를 애착 장소 후보라고 설정했다. 사후 분석에서는 모델 구성에 사용하지 않은 실험자 1명의 gps 데이터를 분석했다. 그 결과 크게 세 장소에서 애착 장소 후보군이 형성되었음을 알 수 있었다.



그림 2. user25의 gps 데이터 시각화

5. 결론

본 논문에서는 모바일 웨어러블 디바이스 E4로부터 얻어진 Acc, Bvp, Eda, Hr, Temp를 이용하여 장소를 예측할 수 있는 딥러닝 모델을 개발하였다. 다양한 구조의 모델 중 3개의 1D Convolution Layer 병합으로 이루어진 MR-CNN 모델이 가장 높은 예측 성능을 보였다. 그 후 사후 분석을 통해 애착 장소 후보군을 정의하였다.

이를 활용하여 사용자 위치 기반 개인화 마케팅을 고려할 수 있다. 사용자가 애착 장소에 도착하였을 때 이벤트를 제시함으로써 애착 장소에서 느끼는 긍정적인 감정을 통해 브랜드 이미지 향상에 효과를 줄 수 있다.

향후 연구에서는 연속적인 장기 데이터 기반 정교한 모델링을 통해 보다 정확한 분석이 가능하다. 또한, 이후의 사후 분석에서 “other_indoor” 외의 다른 장소를 애착 장소 후보로 설정하여 연구 주제의 확장이 가능하다.

참고 문헌

- [1] 김동근. 단기 주거에서의 장소애착에 대한 연구. 한국도시설계학회지 도시설계, 12(5), pp. 79-80, 2011.
- [2] 이형상, 장소 기억하기를 통한 대학생의 장소애착 구조에 관한 연구, 한국지리학회지, 8(2), pp. 121-138, 2019.
- [3] Cho, Young Chang, and Kim, Min Soo. “Characteristics in HRV(Heart Rate Variability), GSR(Galvanic Skin Response) and Skin Temperature for Stress Estimate.” Journal of the Korea Industrial Information Systems Research, vol. 20, no. 3, pp. 11-18, 2015.
- [4] 곽명섭, 백승원, 한경식, 모바일 웨어러블 기기에서 측정된 생체 신호를 이용한 감정 예측, 한국HCI학회 학술대회, pp. 732-734, 2021.
- [5] Valenza, G., Citi, L., Lanata, A., Scilingo, E. P., & Barbieri, R., Revealing real-time emotional reactions: a personalized assessment based on heartbeat dynamics. Scientific reports, 4(1), pp. 1-8, 2014.
- [6] Koelstra, S., Muhl, C., Soleymani, M., Lee, J. S., Yazdani, A., Ebrahimi, T., ... & Pun, T. Deap: A database for emotion analysis; using physiological signals. IEEE transactions on affective computing, 3(1), pp. 18-31, 2012.

[7] 황혜진. 사용자 위치 기반 데이터를 활용한 패턴분석 및 장소 분류에 관한 연구. 석사학위논문. 아주대학교, 경기도. 2016.

[8] 이시혁, 조성배, 사용자의 의미장소 추출 및 인식을 위한 스마트폰 라이프로그 마이닝. Telecommunications Review, 24(3), pp. 371-382, 2014.

[9] 김태성, 이원희, 피부전도도를 이용한 Attention 기반 자동 스트레스 검출 딥러닝 알고리즘 개발, 한국정보과학회, pp. 611, 2022.

[10] S. Chung, C. Y. Jeong, J. M. Lim, J. Lim, K. J. Noh, G. Kim, and H. Jeong, “Real-world multimodal lifelog dataset for human behavior study,” ETRI Journal, 43(6), pp. 1-12. 2021

[11] 조영욱, 정면걸, 김광욱, 신체움직임 측정 방법론에 따른 감정 인식 성능 비교 예비 연구, 한국컴퓨터그래픽스학회 학술대회, pp. 74-75, 2021.